
Descubrimiento causal neuronal a prueba

¿Ventajas reales del DAG-GNN frente a baselines no neuronales?

Diego Alonso Córdova Ayala

diego.cordova@dmg-pe.com · Curso de Redes Neuronales y Deep Learning

Tesis. En los *benchmarks* sintéticos, la ventaja de DAG-GNN es en gran parte **instrumental** (dependiente de la escala), no una mejor recuperación causal.

Motivación: descubrimiento causal por Deep Learning

- **Descubrimiento causal:** inferir el grafo dirigido acíclico (DAG) que genera los datos, no solo correlaciones.
- Reformulado como **optimización continua**:
 - NOTEARS (lineal) y **DAG-GNN** (red neuronal en grafo).
- Prometen capturar **no linealidad** y superar a los clásicos (PC, GES).

$$X_j = f_j(\text{PA}_j, U_j)$$

cada variable = función de sus *padres* +
ruido

¿La flexibilidad neuronal realmente ayuda?

La trampa: *varsortability* (Reisach et al., 2021)

- En los grafos sintéticos habituales, la **varianza marginal crece** a lo largo del orden causal.
- Ordenar por varianza ya “filtra” el orden causal: un método trivial (**sortnregress**) iguala a los sofisticados.
- **Sospecha**: el desempeño no mide razonamiento causal, sino sensibilidad a la **escala**.

Varsortability $v \in [0, 1]$: $v = 1 \Rightarrow$ la varianza revela el orden causal • $v = 0.5 \Rightarrow$
azar

Pregunta de investigación y contribución

Pregunta

¿*Bajo qué condiciones de los datos* la flexibilidad de DAG-GNN produce mejoras **reales** sobre baselines no neuronales?

Contribución — un protocolo experimental controlado que:

1. **varía la varsortability** vía la política de escalas de ruido;
2. **separa** *esqueleto* de *orientación*;
3. contrasta datos **crudos vs. estandarizados**;
4. se **valida en datos reales** (red de proteínas de Sachs, 2005).

Implementación reproducible que mejora el código de Reisach et al.

Notación I: modelo causal, DAG y lo identificable

- **Modelo Causal Estructural (MCE):** $\langle U, V, F, P(U) \rangle$; ecuaciones $X_j = f_j(\text{PA}_j, U_j) \Rightarrow$ un DAG.
- **Límite de identificabilidad:** con datos observacionales (Markov + fidelidad) solo se identifica la **clase de equivalencia de Markov** = un **CPDAG**.

Dos DAGs con el **mismo esqueleto** y las mismas **v-estructuras** ($a \rightarrow c \leftarrow b$) son *indistinguibles* de los datos. $\Rightarrow$ separamos **esqueleto** (*¿hay arista?*) de **orientación** (*¿en qué sentido?*).

Notación II: datos y definición de *varsortability*

SEM lineal (ANM):

$$X = X W + E$$

W : pesos $i \rightarrow j$; E : ruido independiente.

Política de escalas del ruido $\Rightarrow$ controla v :

- *increasing*: Var crece con la profundidad
 $\rightarrow v \rightarrow 1$
- *equal / random*

Varsortability:

$$v = \frac{\sum_{k=1}^{d-1} \sum_{i \rightarrow j \in E^k} 1 \left[\frac{\text{Var}(X_j)}{\text{Var}(X_i)} > 1 \right]}{\sum_{k=1}^{d-1} \sum_{i \rightarrow j \in E^k} 1}$$

(empates = $\frac{1}{2}$). Acuerdo entre el orden de varianzas y el orden causal a lo largo de caminos E^k .

Estandarizar (media 0, var. 1) $\Rightarrow v = 0.5$: se borra la señal de escala.

Métodos comparados (1 principal + 4 baselines)

sortnregress

baseline *trivial*: ordena por varianza y regresa (Lasso-BIC).

NOTEARS

opt. continua lineal con $h(W) = \text{tr}(e^{W \circ W}) - d = 0$.

DAG-GNN

VAE en grafo; $h(A) = \text{tr}[(I + \frac{1}{d} A \circ A)^d] - d = 0$.

PC / GES

clásicos (restricciones / *score*); **invariantes a escala** $\rightarrow$ CPDAG.

$h(\cdot) = 0 \iff$ la matriz de pesos codifica un **DAG**. DAG-GNN lo optimiza con **Lagrangiano aumentado**:
 $\min \text{ELBO} + \alpha h + \frac{\rho}{2} h^2$. Las MLP por nodo aportan la “flexibilidad” cuyo beneficio *real* evaluamos.

Métricas: separar esqueleto de orientación

- **SHD**: aristas faltantes + sobrantes + invertidas.
Menor es mejor.
- **F1 de esqueleto**: $F_1 = \frac{2PR}{P + R}$ sobre aristas *no dirigidas*.
- **Precisión de orientación**: fracción bien orientada entre las detectadas (no dirigida del CPDAG = 0.5).

Por qué separar: un método puede acertar el *esqueleto* y aún así *orientar al azar*. El SHD solo no lo revela.

Diseño experimental

- DAGs Erdős–Rényi, $d = 12$ nodos, ≈ 15 aristas; $n = 1000$.
- **18 condiciones** = 3 políticas (v) $\times$ 2 escalas $\times$ 3 semillas.
- Cada condición: los 5 métodos $\rightarrow$ SHD, F1 esqueleto, orientación.

	crudo (raw)	estandarizado (std)
varsortability	≈ 1	$= 0.5$
<i>¿qué esperamos?</i>	métodos de escala “ganan”	se cae la ventaja de escala

Reproducibilidad: semillas, hiperparámetros, hardware y versiones documentados.


Resultados (sintéticos): la ventaja es instrumental

Escala	Método	v	SHD↓	$F1_{\text{esq}}$	Orient.
crudo	sortnregress	1.0	0.22	0.99	1.00
crudo	NOTEARS	1.0	0.44	0.99	0.99
crudo	DAG-GNN	1.0	5.33	0.78	0.98
crudo	PC / GES	1.0	6.9 / 7.8	0.97 / 0.93	0.76 / 0.73
estand.	sortnregress	0.5	17.6	0.73	0.53
estand.	NOTEARS	0.5	11.1	0.75	0.50
estand.	DAG-GNN	0.5	13.0	0.20	0.80 [†]
estand.	PC / GES	0.5	6.9 / 7.8	0.97 / 0.93	0.76 / 0.73

[†] sobre el $\sim 20\%$ de aristas que conserva; no indicativa.


Al estandarizar, PC y GES pasan a ser los mejores.

La orientación cae a azar al estandarizar



- **Crudo:** NOTEARS/DAG-GNN/sortnregress orientan casi perfecto.
- **Estandarizado:** caen a ≈ 0.5 (azar).
- **PC y GES** estables (invariantes a escala).


Separar esqueleto y orientación es esclarecedor



- En std el **esqueleto** (verde) sobrevive en parte...
- ...pero la **orientación** (rojo) colapsa al azar.
- La “orientación” 0.80 de DAG-GNN es *engañosa*: pocas aristas (SHD= **13**).
- **Costo**: DAG-GNN $\sim$ **5.8** s vs. 0.06–0.34 s; el más caro, no el más preciso.

Validación en datos reales: red de proteínas de Sachs (2005)

Método (escala)	SHD↓	F1 _{esq}	Orient.
NOTEARS (crudo)	19	0.67	0.54
NOTEARS (std)	15	0.38	0.50
PC (crudo=std)	17	0.62	0.38
GES (crudo=std)	17	0.58	0.36



- Datos **reales**, $d = 11$ proteínas; *ground truth* de consenso (17 aristas).
- **Varsortability real = 0.59** (no ≈ 1): **sin** señal de escala artificial.
- **PC y GES idénticos** en crudo y std $\Rightarrow$ invariancia confirmada.
- Ningún método recupera bien la red (SHD 14–19).

La superioridad “sintética” **no se transfiere** a datos reales.

Conclusiones

1. En *benchmarks* ANM lineales, la superioridad de NOTEARS/DAG-GNN es **instrumental**: depende de una alta varsortability que un baseline trivial también explota.
2. Al **estandarizar**, la ventaja se evapora; **PC y GES** resultan preferibles.
3. En **datos reales** (Sachs, $v = 0.59$) la ventaja no aparece.

Recomendaciones metodológicas

(i) estandarizar como **control estándar**; (ii) reportar **esqueleto y orientación por separado**; (iii) la evidencia *no* respalda adoptar DAG-GNN por su flexibilidad no lineal en este régimen.

La ventaja es **instrumental**, no causal.

Gracias.

`diego.cordova@dmg-pe.com`

[Código en GitHub](#) · [README](#) · [reproducibilidad](#)